Controle Doméstico Simulado com Modelos Pequenos em SBCs: Sucesso de Tarefas, Latência e Replicação

Hudson Moreira Guimarães dos Santos*, Bruno Cavalcante de Souza Sanches*,
Laisa Caroline Costa De Biase*, Roseli de Deus Lopes*, Marcelo Knörich Zuffo*,
Pablo Cesar Calcina Ccori*
*University of São Paulo (USP), São Paulo, Brazil
Autor correspondente: Hudson Moreira Guimarães dos Santos (hudson.moreira@usp.br)

***Resumo*—Avaliamos uma referência de regras finitas e os modelos Qwen2.5 de 0.5B e 1.5B quantizados em computadores de placa única (SBCs) Labrador. A casa e todas as ações são simuladas; hardware e inferência são reais. Quarenta cenários reservados abrangem pedidos claros, paráfrases, rotinas explícitas, ambiguidades e solicitações inválidas, com duas repetições por condição. A média de sucesso agrupa as repetições por cenário, enquanto as estatísticas de latência descrevem requisições individuais. A média de sucesso por cenário foi 52.5% nas regras, 37.5% no 0.5B e 15.0% no 1.5B, com medianas por requisição de 0.157, 36.848 e 94.663 s, respectivamente. Réplicas independentes em uma, três e seis placas atendem um lote fixo de seis pedidos. Os registros distinguem propostas do modelo de intervenções do executor e preservam falhas. As conclusões se restringem às configurações e casos construídos, sem estimar precisão residencial geral ou capacidade máxima do serviço.**

***Palavras-chave*—casa simulada, modelos pequenos, SBC, avaliação, latência**

I. Introdução e pergunta de pesquisa

Controlar ações domésticas por linguagem natural exige identificar a ação, pedir informações ausentes e rejeitar instruções não representáveis. Produzir JSON válido não comprova que a proposta é correta. Em uma SBC, a decisão também deve ser avaliada em relação ao tempo de resposta e à memória. Perguntamos: como uma referência de regras e dois modelos pequenos quantizados diferem em conclusão de tarefas e latência, e como muda a taxa de respostas corretas em lotes fixos com réplicas independentes?

HomeBench avalia instruções válidas e inválidas para um ou vários dispositivos em ambiente virtual [1], motivando a distinção entre validade sintática e propostas indevidas. Lu et al. examinam conjuntamente capacidade de modelos pequenos e custos de implantação, incluindo processamento do prompt, geração, quantização e hardware [2]. Nosso conjunto em português, limitado a dois cômodos, é uma construção independente. Não reproduz HomeBench nem transfere para Labrador conclusões obtidas em outro hardware. Qin et al. [3] estudam seleção e personalização de modelos sob restrições de borda, considerando dificuldade da tarefa, customização, compressão, dados e tempo de aprendizagem. Nosso foco é custo de inferência e decisões domésticas simuladas com modelos pré-treinados fixos. Isso motiva avaliar conjuntamente modelo, tarefa e recursos; comparar 0.5B/1.5B não replica seus experimentos de personalização nem confirma causalmente suas diretrizes. As contribuições são separar propostas de ação, intervenção do executor e resultados em registros auditáveis; comparar conjuntamente regras finitas e duas configurações de modelos pequenos em hardware ARM; e estudar replicação em lotes fechados com limites de medição explícitos. Avaliam-se qualidade da decisão e custo de implantação, sem propor um novo modelo ou sistema residencial.

II. Arquitetura e limites de decisão

Um coordenador Python constrói um estado simulado novo para cada pedido, consulta um serviço HTTP residente, valida o JSON, aplica mudanças permitidas em dicionários e avalia o resultado separadamente. Nenhum dispositivo doméstico está conectado ao executor. O domínio contém sala e quarto, luzes on/off, ações simples, uma rotina explícita de dois passos, esclarecimento e rejeição. O esquema aceita `set_light`, `set_lights`, `ask_clarification` e `no_action`. Um plano é atômico: a falha de permissão de qualquer passo impede a aplicação de todo o plano.

O executor recebe somente pedido, estado visível e permissões. Não consulta estados esperados, propostas proibidas, categoria do cenário ou qualquer gabarito. Uma política geral conservadora bloqueia propostas de iluminação quando o pedido não menciona nenhum nome de cômodo conhecido como palavra inteira e a localização não é válida. Cômodos desconhecidos ou valores não autorizados também são bloqueados. Havendo informação de local, uma proposta para o cômodo errado pode chegar ao simulador; o avaliador independente identifica o erro. Presença lexical de cômodo não valida a intenção em frases negativas ou pedidos inválidos. Proposta, bloqueio, mudança aplicada e sucesso são registrados separadamente.

Esclarecimento exige solicitar o cômodo ausente, preservar o estado e não propor ação indevida. Padrões conservadores de pergunta completa reconhecem solicitações explícitas como "Qual cômodo?". Mencionar uma palavra de cômodo é insuficiente. Outras perguntas entram em um registro de revisão

caso a caso, com identificação e justificativa do revisor; pendências não recebem sucesso automático. Revisões assistidas são distinguidas de revisão humana.

III. Plataforma e protocolo congelado

As seis placas Labrador informam quatro núcleos ARM64, Debian 12 e aproximadamente 1.89 GiB de RAM visível ao sistema. Binário e todas as bibliotecas compartilhadas foram conferidos por SHA-256. O `llama-server` [4] é build 9584/`e25a32e98`, executado em CPU, com quatro threads de cálculo e quatro de lote, contexto 512 e uma vaga por modelo residente. Os dois servidores permanecem carregados em cada placa, com no máximo uma inferência ativa entre eles. Qwen2.5-0.5B-Instruct e Qwen2.5-1.5B-Instruct [5], [6] são avaliados como arquivos locais Q5_K_M GGUF, com hashes preservados. Os hashes coincidem com os arquivos GGUF publicados oficialmente por Qwen [7], [8], estabelecendo identidade byte a byte, além de nomes e metadados. O procedimento histórico de download local não foi preservado.

A referência de regras é um serviço Python HTTP residente e sem estado nas mesmas placas. Sua gramática finita reconhece acenda/ligue e apague/desligue, cômodos explícitos, conjunções simples, comandos com localização conhecida e fórmulas de cortesia nas extremidades. Formas não reconhecidas retornam `no_action`. Essa referência de engenharia tem cobertura limitada e não representa o melhor sistema possível de regras para linguagem natural.

Oito casos de desenvolvimento antecederam o congelamento. Um primeiro prompt compacto expôs mudanças em luzes não solicitadas. Uma segunda campanha verificou instruções gerais de preservação e a correção da cortesia nas regras. Ambas são preservadas separadamente. Não havia resultados reservados durante a seleção de configuração. O manifesto congela cenários, estados e passos esperados, prompt, esquema, política de bloqueio, configurações, repetições e medição. Cada inferência usa um modelo completo em uma placa, sem divisão do modelo nem colaboração entre agentes.

O conjunto principal tem oito casos em cada uma de cinco categorias (40 casos distintos). Cada condição possui duas repetições por caso ($n = 80$ requisições; 240 no total). Cada modelo é distribuído por todos os hosts e as repetições de um caso usam placas distintas. A fila de cada host é sequencial; não há inferências concorrentes do controlador na mesma placa. As entradas usam instrução geral compacta em inglês e pedido em português, temperatura zero, sementes 801/802, limite de 128 tokens e timeout de 180 s. O cache é desativado, com contagem efetiva preservada. Temperatura zero limita diversidade; as repetições verificam estabilidade operacional.

Sucesso exige conjuntamente conclusão operacional normal (HTTP completo e geração terminada normalmente), JSON válido no contrato, ação/passos corretos, estado final esperado, preservação do restante e ausência de passos proibidos ou extras. Pedidos claros e paráfrases exigem a mudança solicitada, preservando a outra luz; um plano de um passo equivale a uma ação simples. Rotinas exigem exatamente os dois passos previstos. Ambiguidades exigem pergunta informativa sobre o cômodo ausente e luzes intactas; pedidos inválidos exigem `no_action` e luzes intactas.

Falha operacional impede conclusão normal; falha de formato viola o contrato de saída. Falhas semânticas/de decisão violam ação, esclarecimento, rejeição ou estado, mesmo com resposta válida. A intervenção do executor é uma decisão separada de permissão: bloquear uma proposta incorreta não torna a tarefa bem-sucedida. Retornar `no_action` é correto em pedido inválido, mas falha em comando válido ou pedido que exige esclarecimento. As duas repetições são agrupadas por cenário, com peso igual por caso nas categorias. Não se usam as repetições como casos independentes para inferência populacional ou significância.

IV. Medição

O relógio monotônico do coordenador mede do despacho HTTP até a leitura e decodificação da resposta, incluindo rede e inferência e excluindo carregamento do modelo e instantâneos SSH. Mediana e p95 por posto mais próximo são estatísticas descritivas com tamanho de amostra informado. Tokens e tempos de prompt/geração vêm do runtime; regras não têm tokens de modelo. RSS é observado antes/depois, enquanto VmHWM é o máximo desde o início do processo, não pico individual. RSS descreve cada processo e pode incluir mapeamentos compartilhados, não memória física exclusiva do modelo. Serviços residentes anteriores são documentados; não se afirma memória exclusiva da placa.

A escala usa réplicas independentes, uma requisição por placa em cada onda, uma/três/seis placas ativas e dois lotes de seis pedidos por tamanho/condição (108 requisições). Os mesmos seis casos abrangem um claro, uma paráfrase, duas rotinas, uma ambiguidade e um inválido. A janela vai do primeiro despacho à última resposta e inclui intervalos instrumentados entre ondas. Latência individual, respostas/min e tarefas corretamente concluídas/min são separados. A taxa divide tarefas julgadas corretas pela janela de respostas HTTP; a aplicação final no simulador e a avaliação ocorrem após o recebimento. É uma taxa de respostas corretas às tarefas, não tempo medido até mudar o estado físico ou simulado. Esse lote fechado não mede saturação, latência com chegadas enfileiradas ou capacidade máxima. Cada requisição parte de estado novo, sem histórico de conversa. O controlador aguarda ociosidade dos dois modelos após eventual timeout antes de enviar outro pedido.

V. Resultados

A. Qualidade e latência reservadas

As 240 respostas foram estruturalmente válidas e terminaram normalmente; validade do esquema não comprovou controle correto. Regras concluíram 42/80 tentativas, Qwen 0.5B 30/80 e Qwen 1.5B 12/80, todas creditadas automaticamente. Regras acertaram as 16 tentativas claras e as 16 inválidas, mas nenhuma das 16 paráfrases. O 0.5B acertou 14/16 paráfrases, mas não rejeitou corretamente nenhum pedido inválido. Nenhum modelo concluiu caso ambíguo pelos critérios registrados; quatro julgamentos do 0.5B permanecem

Tabela I
TENTATIVAS RESERVADAS POR CONDIÇÃO ($n = 80$ REQUISIÇÕES, 40 CENÁRIOS). LATÊNCIA EM SEGUNDOS; P95 POR POSTO MAIS PRÓXIMO. INDEVIDAS E BLOQUEIOS CONTAM COMANDOS DE LUZ EM RESPOSTAS ESTRUTURADAS VÁLIDAS, NÃO CASOS ÚNICOS OU PLANOS COMPLETOS.

Condição	Sucesso	Mediana	p95	Indevidas	Bloq.
Regras	42/80	0.157	0.643	0	0
Qwen 0.5B	30/80	36.848	45.292	36	16
Qwen 1.5B	12/80	94.663	159.117	76	22

Tabela II
SUCESSO POR CATEGORIA: OITO CENÁRIOS COM DUAS REPETIÇÕES (16 TENTATIVAS) POR CÉLULA. AS FRAÇÕES POR CENÁRIO ESTÃO NO CSV REPRODUZÍVEL. *QUATRO JULGAMENTOS DO 0.5B EM AMBIGUIDADE AGUARDAM VALIDAÇÃO HUMANA; NENHUM SUCESSO É ASSISTIDO.

Categoria	Regras	0.5B	1.5B
Instruções claras	16/16	8/16	0/16
Paráfrases	0/16	14/16	4/16
Rotinas	8/16	8/16	6/16
Ambiguidade	2/16	0/16*	0/16
Pedidos inválidos	16/16	0/16	2/16

provisórios. As frações por categoria agrupam duas repetições de cada um dos oito cenários, não 16 cenários independentes.

Quatro respostas de esclarecimento do 0.5B têm julgamentos assistidos de falha aguardando validação humana no registro preservado. São provisoriamente malsucedidas; nenhum sucesso apresentado depende de revisão assistida. Mesmo creditando as quatro, o 0.5B alcançaria 34/80 (42.5%), abaixo das regras com 42/80 (52.5%). Esse limite de sensibilidade não substitui revisão semântica.

Por comando, o 0.5B propôs 36 mudanças indevidas de luz, 16 bloqueadas e 20 aplicadas somente no simulador; o 1.5B propôs 76, 22 bloqueadas e 54 simuladas. Esses números diferem dos diagnósticos por resposta, que podem incluir passos omitidos. A mediana de RSS após a requisição foi 571.6 MiB no 0.5B e 1183.7 MiB no 1.5B. Ambos usaram 124–138 tokens de entrada; as saídas variaram de 16–40 e 12–75 tokens. As contagens registradas de cache de prompt foram zero.

B. Critérios reprovados e casos ilustrativos

Uma análise complementar posterior agrupa verificações existentes do avaliador, contando cada grupo no máximo uma vez por tentativa. Não muda o avaliador congelado nem os resultados. A Tabela III apresenta requisitos reprovados, não causas exclusivas: estado, passos e permissão podem falhar juntos. O artefato registra nomes exatos, mapeamentos de prefixos, contagens de verificações observadas/aprovadas/reprovadas/ausentes e caminhos das tentativas. Ausência não é aprovação: esclarecimento só é verificado quando proposto. A decomposição completa inclui ação esperada incorreta nos casos ambíguos/inválidos; igualdade de passos trata os invólucros de iluminação. As 38 tentativas

Tabela III
REQUISITOS REPROVADOS POR TENTATIVA (80 POR CONDIÇÃO); LINHAS SE SOBREPÕEM E NÃO DEVEM SER SOMADAS. PARÊNTESES INDICAM TENTATIVAS APLICÁVEIS/OBSERVADAS: PASSOS E ESTADO-ALVO ABRANGEM CLAROS/PARÁFRASES/ROTINAS; PRESERVAÇÃO EXCLUI ROTINAS; p INDICA RESPOSTAS PROPOSTAS DAQUELE TIPO. PROIBIÇÕES SÃO VERIFICADAS EM 80, MAS SÓ 32 CASOS AMBÍGUOS/INVÁLIDOS TÊM PROIBIÇÕES NÃO VAZIAS. *QUATRO FALHAS AGUARDAM VALIDAÇÃO HUMANA; –/0 INDICA AUSÊNCIA DE PROPOSTA, NÃO CAPACIDADE DEMONSTRADA.

Requisito (denominador)	Regras	0.5B	1.5B
Passos diferentes (48)	24	18	38
Estado-alvo incorreto (48)	24	18	22
Preservação falhou (64)	0	8	14
`no_action` indevido (p)	38	4	20
Proposta bloqueada (80)	0	14	12
Passo proibido (80)	0	26	24
Esclarecimento inadequado (p)	0/2	12/12*	–/0

malsucedidas das regras retornaram `no_action` fora da política de rejeição: 16 paráfrases, 8 rotinas e 14 ambiguidades. Preservaram estados não relacionados, mas omitiram ações ou esclarecimento exigidos. O 0.5B propôs passos de luz proibidos em 14/16 pedidos inválidos e esclarecimento inadequado nos outros 2; 8 tentativas inválidas alteraram estados protegidos. No 1.5B, todas as 16/16 tentativas claras tiveram passos incorretos, mas só 8 falharam no estado-alvo: acertar o valor da luz pedida pode esconder uma mudança extra. Suas 38 tentativas com passos incorretos e 14 falhas de preservação caracterizam esta configuração, sem estabelecer por que ela se comportou assim.

Esclarecimentos propostos/corretos foram 2/2, 12/0 e 0/0 para regras, 0.5B e 1.5B. Os 12 esclarecimentos do 0.5B falharam no critério da pergunta; 4 têm julgamento assistido provisório. O 1.5B não propôs esclarecimentos: zero falhas nessa verificação não demonstra capacidade de esclarecer. Os denominadores p de `no_action` propostos são 54, 4 e 22.

Os exemplos a seguir ilustram comportamentos registrados, sem explicar causas ou substituir contagens. IDs são nomes dos diretórios de tentativas da campanha de qualidade; JSON completo, estados inicial/esperado/final, verificações e caminhos estão no artefato complementar. Pedidos e trechos de saída são literais; a notação de ações abrevia campos JSON registrados.

E1 (`rules-held-paraphrase-01-rep1-169`).

"Por favor, deixe a luz da sala ligada." exige sala=on e quarto=on preservado. Regras retornaram `no_action` com motivo "Pedido fora das regras explícitas.". Não houve bloqueio; sala ficou off. Falharam estado final, passos exatos e política de no-action.

E2 (`05-held-ambiguity-01-rep1-169`).

"Ligue a luz, por favor.", sem localização conhecida, exige perguntar o cômodo. O 0.5B retornou `set_light`, `room=sala`, `value=on`. O executor bloqueou por informação insuficiente de cômodo; luzes preservadas (sala=off, quarto=on). Falharam permissão, ação esperada e passos proibidos, apesar da preservação.

Tabela IV
DOIS LOTES DE SEIS PEDIDOS POR CONDIÇÃO/TAMANHO. TAXA: MÉDIA DE TAREFAS CORRETAS/MIN; MEDIANA E P95 INDIVIDUAIS USAM $n = 12$ REQUISIÇÕES. INTERVALOS DOS LOTES E RESPOSTAS/MIN ESTÃO NO ARTEFATO.

Condição	Placas	Sucesso	Taxa	Mediana	p95
Regras	1	10/12	42.753	0.006	0.211
Regras	3	10/12	235.196	0.006	0.008
Regras	6	10/12	30555.536	0.006	0.011
Qwen 0.5B	1	6/12	0.871	24.586	37.903
Qwen 0.5B	3	6/12	2.883	23.993	40.917
Qwen 0.5B	6	6/12	6.393	23.990	28.772
Qwen 1.5B	1	2/12	0.085	84.187	131.203
Qwen 1.5B	3	2/12	0.289	78.606	139.278
Qwen 1.5B	6	2/12	0.661	80.019	93.518

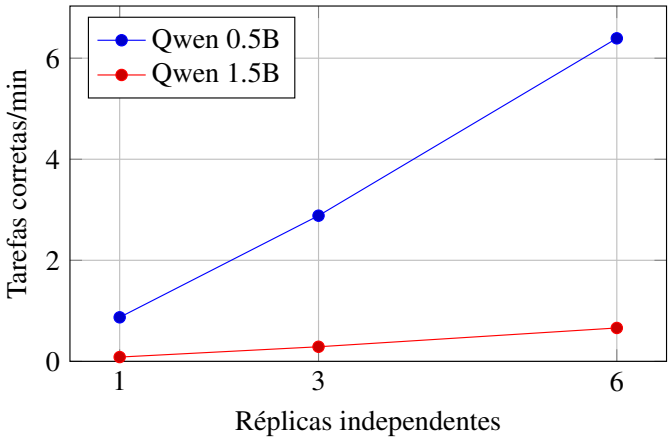


Figura 1. Tarefas corretas/min, médias de dois lotes fechados instrumentados. Latência individual e erros são apresentados separadamente; as curvas não demonstram capacidade máxima.

E3 (`05-held-ambiguity-03-rep1-240`).

"Quero a luz acesa.", sem localização conhecida, também exige perguntar o cômodo. O 0.5B retornou `ask_clarification`, `missing_field=room`, com pergunta "Quero a luz acender.". Sem bloqueio nem mudança (sala=off, quarto=on). Apenas a pergunta informativa falhou provisoriamente: o julgamento registrado por Codex aguarda validação humana.

E4 (`15-held-clear-01-rep1-240`).

"Ligue a luz na sala." exige apenas sala=on, preservando quarto=on. O 1.5B retornou plano `set_lights` com `(sala,on)` e `(quarto,off)`. Ambos os comandos foram permitidos e simulados; final sala=on, quarto=off. Falharam passos exatos e preservação, embora a luz-alvo estivesse correta. Uma resposta contém dois comandos, com uma mudança extra.

C. Serviço replicado

O CSV de lotes preserva cada janela, taxa de tarefas corretas e taxa de respostas separadamente. A Tabela IV agrupa doze requisições por condição/tamanho para latência e calcula a média de duas taxas de lote; os intervalos permanecem no resumo legível por máquina.

No 0.5B, as médias de respostas corretas às tarefas foram 0.871, 2.883 e 6.393/min com uma, três e seis réplicas; no 1.5B, 0.085, 0.289 e 0.661/min. Cada lote de seis pedidos manteve três tarefas corretas no 0.5B, uma no 1.5B e cinco nas regras. A taxa das regras em seis réplicas reflete janela de respostas de cerca de 9–11 ms e ausência dos intervalos de instrumentação entre ondas; não deve ser interpretada como capacidade sustentada medida.

VI. DISCUSSÃO E LIMITAÇÕES

Conclusão de tarefa e validade estrutural são resultados distintos. Uma proposta incorreta bloqueada continua sendo erro de decisão do modelo; aumentar o volume de respostas não corrige essa decisão. A replicação muda a concorrência de atendimento, mantendo modelo e contrato do simulador. O perfil de falhas explica o que o sucesso agregado esconde: o 0.5B atende mais destas paráfrases que as regras, mas perde em rejeição de inválidos e preservação. O 1.5B apresenta maior latência e mais propostas com passos incorretos nesta configuração; não se isolou experimentalmente tamanho ou mecanismo interno de raciocínio. LoRA, RAG ou especialização exigiriam novos dados de desenvolvimento e protocolo separado; não foram implementados. Decisões simuladas incorretas não comprovam segurança ou insegurança em uma casa real. Os 40 casos são combinações elaboradas de pedido e estado, não 40 casas diferentes; vários expressam a mesma ação. Luzes solicitadas começam no valor oposto, sem testar idempotência ou outras distribuições de estado. Sucesso em rotinas isoladamente não comprova compreensão linguística independente de uma estratégia de inverter o estado. O conjunto é pequeno, em português e restrito a dois cômodos. A gramática das regras é finita, o esquema restringe a geração e há uma quantização por tamanho. Comparam-se configurações completas, sem isolar efeito de parâmetros ou arquitetura. O intercalamento reduz associação entre modelo e host, mas não elimina variações térmicas, de memória e rede. Processos permanecem residentes; caches de disco/páginas não são esvaziados. Não se mede pico individual de memória nem energia. Os lotes de escala são poucos e incluem custos de instrumentação, que podem dominar a referência de regras. Os quatro julgamentos assistidos de esclarecimento são provisórios; seu efeito possível foi limitado acima. A simulação não valida segurança ou usabilidade residencial real.

VII. CONCLUSÃO E PRÓXIMAS ETAPAS

No conjunto reservado, regras concluíram 42/80 tentativas, o 0.5B 30/80 e o 1.5B 12/80; todas as respostas foram estruturadas válidas. O 0.5B acertou 14/16 paráfrases, mas não rejeitou corretamente nenhum pedido inválido. Esses resultados distinguem qualidade da decisão, validade estrutural e intervenção operacional. Os números e latências caracterizam as configurações congeladas nesses casos construídos. Trabalho futuro deve ampliar casos revisados independentemente e formulações de usuários reais antes de aplicação residencial. Colaboração entre agentes e comparações de cache exigem protocolos separados.

Disponibilidade de Evidências e Uso de IA

A análise complementar de falhas, o comando de reprodução e exemplos ligados às tentativas estão na branch de revisão; seu manifesto de insumos liga as fontes à evidência científica original. O protocolo congelado, as 240 tentativas de qualidade e 108 de replicação, respostas brutas, falhas, registro de revisão e scripts de reconstrução estão públicos em um snapshot imutável do repositório [9]. A reprodução confere estado, permissões e avaliação registrados contra cada resposta; os scripts regeneram tabelas e fontes das figuras. Repetir o experimento em hardware exige os arquivos de runtime e modelos registrados; reconstruir análises não constitui replicação independente do hardware.

Não houve financiamento externo. OpenAI Codex auxiliou código, análise, figuras, conferência de evidências e literatura, redação e revisão do manuscrito. Seus quatro julgamentos provisórios de esclarecimento não são revisão humana. Os autores permanecem responsáveis pela verificação e pelo texto final, conforme a orientação IEEE sobre uso de IA [10].

Referências

[1] S. Li, Y. Guo, J. Yao, Z. Liu, and H. Wang, "HomeBench: Evaluating LLMs in smart homes with valid and invalid instructions across single and multiple devices," in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2025, pp. 12 230–12 250. [Online]. Available: https://aclanthology.org/2025.acl-long.597/

[2] Z. Lu, X. Li, D. Cai, R. Yi, F. Liu, W. Liu, J. Luan, X. Zhang, N. D. Lane, and M. Xu, "Demystifying small language models for edge deployment," in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2025, pp. 14 747–14 764. [Online]. Available: https://aclanthology.org/2025.acl-long.718/

[3] R. Qin, D. Liu, C. Xu, Z. Yan, Z. Tan, Z. Jia, A. Nassereldine, J. Li, M. Jiang, A. Abbasi, J. Xiong, and Y. Shi, "Empirical guidelines for deploying LLMs onto resource-constrained edge devices," *ACM Transactions on Design Automation of Electronic Systems*, vol. 30, no. 5, 2025, art. 70. [Online]. Available: https://doi.org/10.1145/3736721

[4] ggml-org, "llama.cpp server documentation," accessed: 2026-10-20; deployed source revision e25a32e98c15a1118a976685af0f4d2c1f380079. [Online]. Available: https://github.com/ggml-org/llama.cpp/blob/e25a32e98c15a1118a976685af0f4d2c1f380079/tools/server/README.md

[5] Qwen, "Qwen2.5-0.5B-Instruct: Official model card," accessed: 2026-10-05. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct

[6] ——, "Qwen2.5-1.5B-Instruct: Official model card," accessed: 2026-10-05. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct

[7] ——, "Qwen2.5-0.5B-Instruct Q5_K_M: Official GGUF file and SHA-256," accessed: 2026-10-06. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct-GGUF/blob/main/qwen2.5-0.5b-instruct-q5_k_m.gguf

[8] ——, "Qwen2.5-1.5B-Instruct Q5_K_M: Official GGUF file and SHA-256," accessed: 2026-10-06. [Online]. Available: https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct-GGUF/blob/main/qwen2.5-1.5b-instruct-q5_k_m.gguf

[9] Labrador Distributed LLM Benchmarks contributors, "Simulated smart-home control: Frozen protocol, raw attempts, and reconstruction scripts," GitHub repository (snapshot a834b82), 2026, evidence snapshot a834b82, accessed 2026-10-20.

[10] IEEE, "Guidelines for artificial intelligence (AI)-generated text," 2024, accessed: 2026-10-20. [Online]. Available: https://open.ieee.org/author-guidelines-for-artificial-intelligence-ai-generated-text/